Stockage et systèmes de fichiers

Guillaume Salagnac

Insa de Lyon – Informatique

2020–2021

Systèmes de fichiers : pour quoi faire ?

Persistence

- conserver les données même quand la machine est éteinte
- dissocier les données du processus qui les a créées
- stockage en dehors de la mémoire principale (RAM)
- notion de fichier non structuré = une séquence d'octets

Organisation

- identifier chaque fichier par un nom intelligible
- grouper des noms ensemble pour ranger les fichiers
- notion de répertoire (= dossier)
- hiérarchie arborescente de répertoires et sous-répertoires

Abstraction

- masquer les détails technologiques : disque, flash, réseau
- architecture logicielle en couches

Bonus : protection, performance, robustesse

Vocabulaire : vous avez dit «fichier» ?

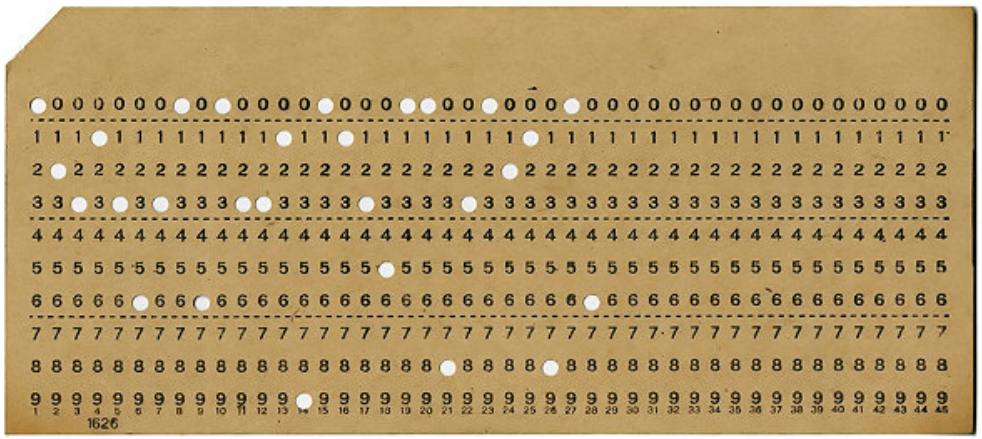

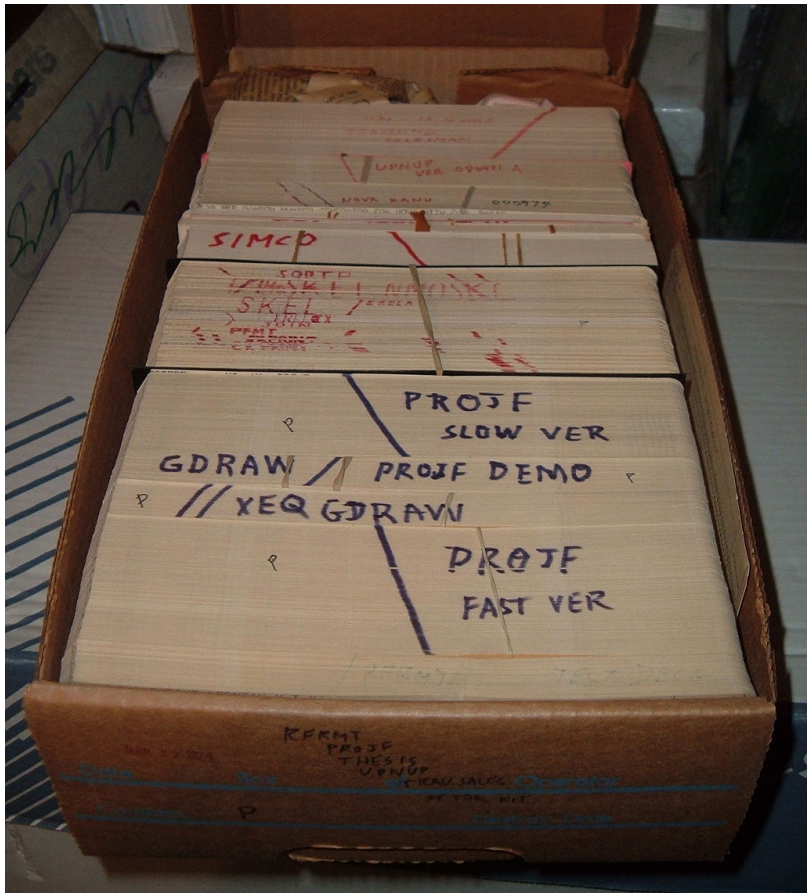

- VF fichier = VO *file*

Vocabulaire : vous avez dit «dossier» ?

≈ 1960

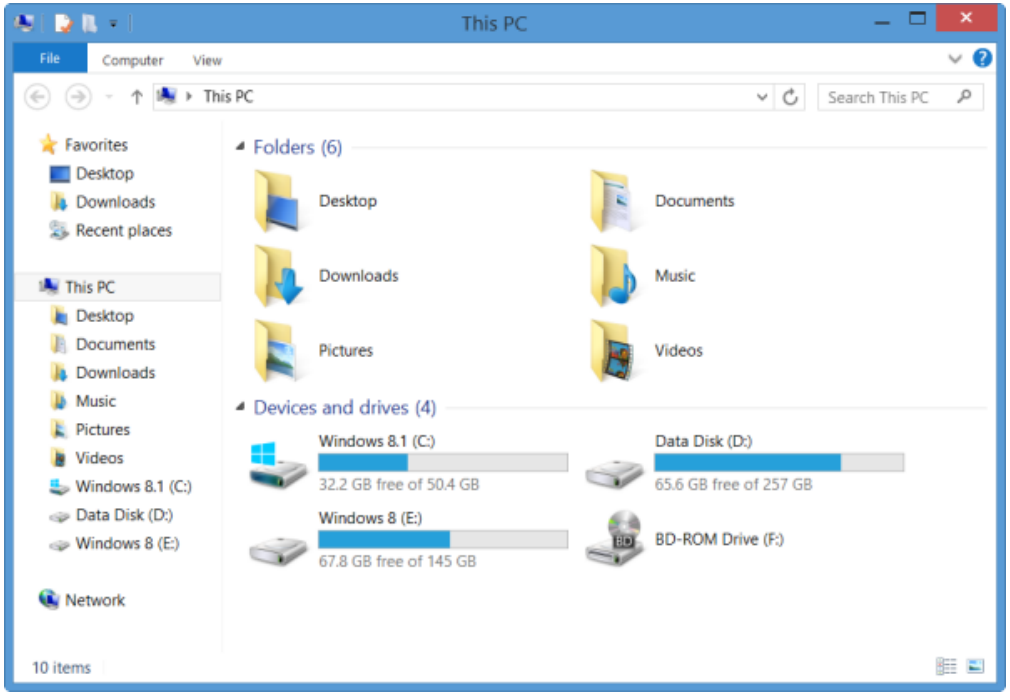

≈ 2015

- VF répertoire (dossier) = VO *directory (folder)*

Systèmes de fichiers : pourquoi c'est difficile

Non-volatilité : chaque écriture sur le disque est définitive

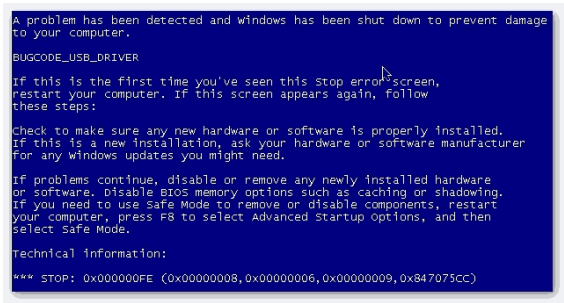

VS

- comment résister aux pannes et aux plantages ?

Latence : un accès disque $\approx$ cent mille accès mémoire !

DRAM $\approx$ 50ns Flash $\approx$ 50μs disque $\approx$ 5ms

Taille : 100$\times$, 1000$\times$ plus vaste que mémoire

- comment offrir une performance acceptable ?

Plan

1. Introduction : définitions, vocabulaire
2. Interface utilisateur : fichiers, répertoires, volumes
3. Implémentation et interface vers le matériel

Positionnement

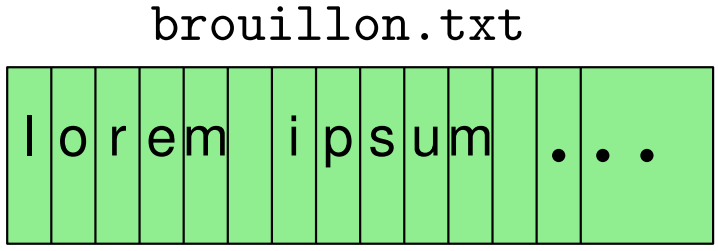

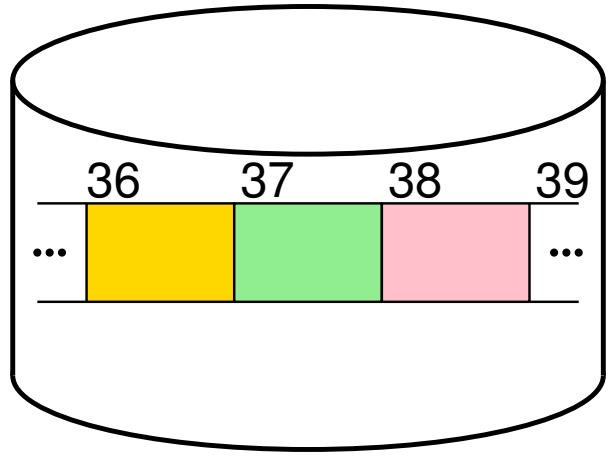

- fichier : conteneur nommé pour une séquence d'octets
  - application interprète «librement» le contenu binaire
  - convention : suffixe du nom (`.mp3`, `.jpg`...) = format des données
- disque : tableau de secteurs numérotés
  - taille typique : un secteur = 512B ou 4kB
  - unité de transfert atomique entre disque et RAM = 1 secteur

Rôle du système de fichiers (en VO File system = FS)

Lors de chaque accès à un fichier, le FS doit traduire une paire nom+position vers une «adresse disque» n° secteur+offset

Interface utilisateur : appels système

```
ssize_t read(int fd, void *buf, size_t count);
```

- Lire *count* octets dans le fichier *fd* et les écrire en mémoire à l'adresse *buf* (donc de *buf* jusqu'à *buf+count–1*)

```
ssize_t write(int fd, const void *buf, size_t count);
```

- Lire en mémoire les *count* octets commençant à l'adresse *buf*, et les écrire dans le fichier *fd*

Remarque : pas besoin de préciser systématiquement le nom du fichier accédé (ni l'offset dans le fichier)

- le numéro `fd` est un file descriptor attribué par le noyau
  - `int open(char *pathname, int flags)` rend un fd
- notion de position courante dans chaque fichier ouvert
  - `off_t lseek(int fd, off_t offset, int whence);`
- liste des fichiers ouverts (et positions) dans le PCB

Opérations disponibles sur un fichier

- créer un nouveau fichier : `creat()`
- supprimer un fichier : `unlink()`
- ouvrir : `open()`
- fermer : `close()`
- lire *n* octets depuis la position courante : `read()`
- écrire *n* octets à la position courante : `write()`
- se repositionner dans le fichier : `lseek()`
- ajouter *n* octets en fin de fichier : `append()`
- lire les méta-données : `stat()`
- changer les méta-données : `chmod()`, `utime()`
- renommer un fichier : `rename()`
- ...

Attention, piège : renommer $\neq$ déplacer ! (cf plus tard)

Organisation des fichiers en dossiers

Objectif : pouvoir retrouver un fichier à partir de son nom

Solutions historiques :

- un seul répertoire contenant tous les fichiers ?
- structure fixe à 2, 3, N niveaux ?

▶ inconfortable à utiliser, et inefficace à l'exécution

Approche moderne : structure de nommage récursive

- chaque dossier peut contenir fichiers et sous-dossiers
- le système de fichiers forme un arbre
- implem : un répertoire = un fichier spécial
  - contient la liste de ses sous-dossiers et fichiers
  - appels système idoines : `opendir()`, `readdir()`...

Arborescence de fichiers Unix

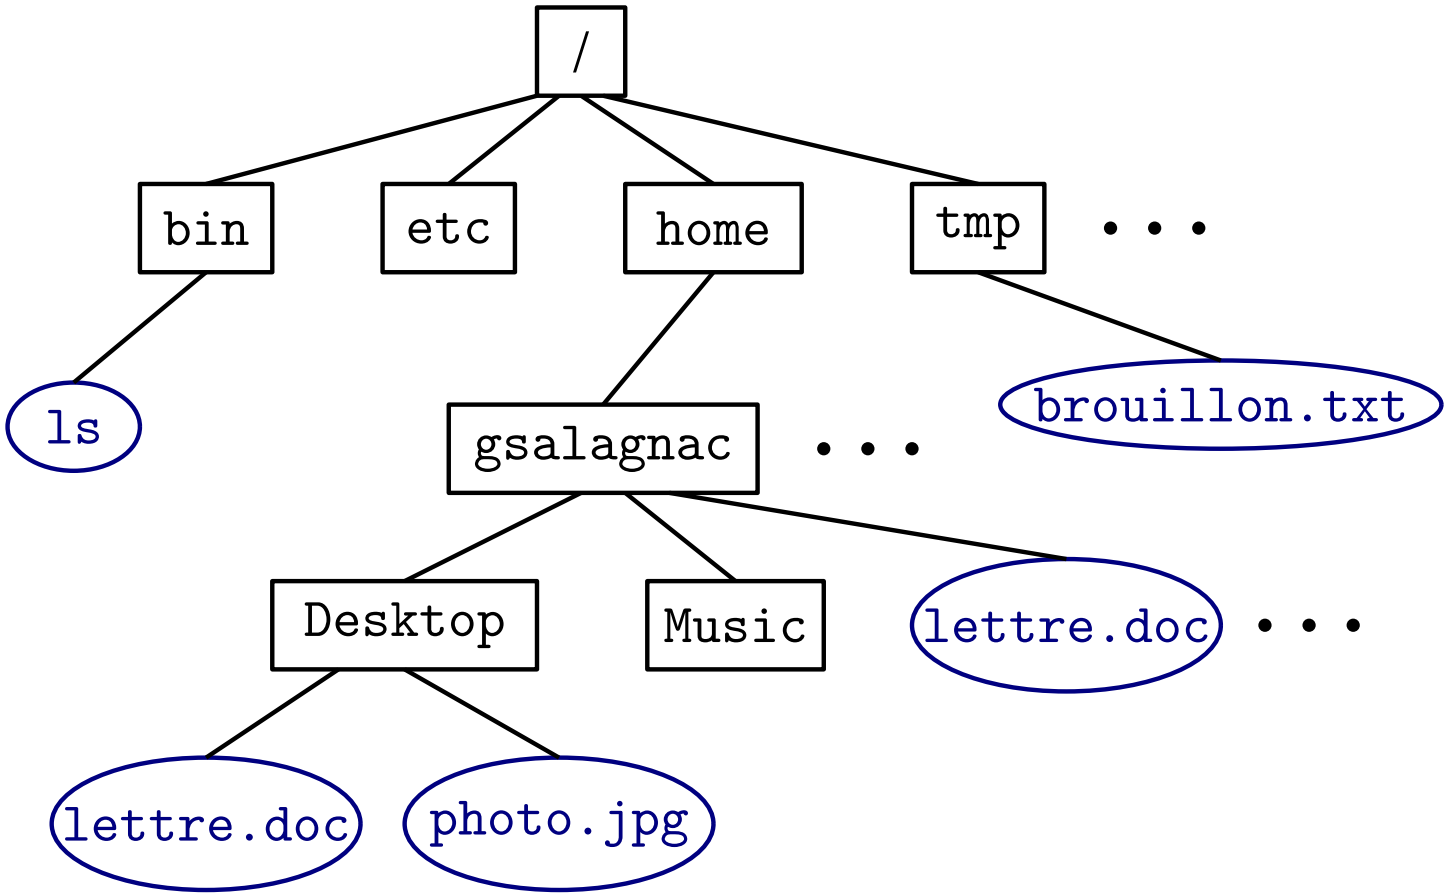

Exemple de chemin absolu :

`/home/gsalagnac/Desktop/photo.jpg`

Arborescence Unix : noms spéciaux

Noms spéciaux du système de fichiers

- racine du système de fichiers `/`
- répertoire courant `.`
- répertoire parent `..`

Mécanisme similaire dans le shell

- mon répertoire personnel `~`
- joker `*.txt` pour dire «tous les noms qui finissent par `.txt`»

Commandes shell

- `cd truc` pour «aller» dans le répertoire *truc*
  - exemples `cd /` `cd /home/gsalagnac/Desktop` `cd ..`
- `ls` pour lister le contenu du répertoire courant

Répertoire courant et chemins relatifs

Chaque processus a un current working directory CWD

- appel système `chdir()` pour changer de CWD
- `cd truc` demande au shell de faire un `chdir("truc")`
- implem : PCB contient un champ pour le CWD

Résolution des noms par le noyau

- chemin commençant par un `/` ▶ chemin absolu
  - interprété en partant de la racine
  - par exemple `/usr/bin/emacs`
- chemin commençant par autre chose ▶ chemin relatif
  - interprété en partant du CWD
  - par exemple `Photos` qu'on peut écrire aussi `./Photos`
  - par exemple `../../Documents/lettre.doc`
- attention : à ne pas confondre avec les raccourcis de syntaxe implémentés dans votre shell (~, jokers...)

Notion de «montage»

- plusieurs supports : disques, DVD, clé USB, réseau...
  - une arborescence sur chaque support : notion de volume logique

vs

- une seule arborescence de fichiers dans le système
  - une seule racine / dans le système

Problème : comment accéder à tous ces fichiers à la fois ?
Solution : inclure les différents volumes dans une unique vue

Définition : montage d'un volume logique

Monter un volume dans un dossier = masquer le contenu de ce dossier et le remplacer par l'arborescence du volume

- Unix : tout répertoire peut servir de point de montage
- Windows : 26 points de montage possibles `A:` `B:` ... `Z:`

Montage : illustration

Avant :

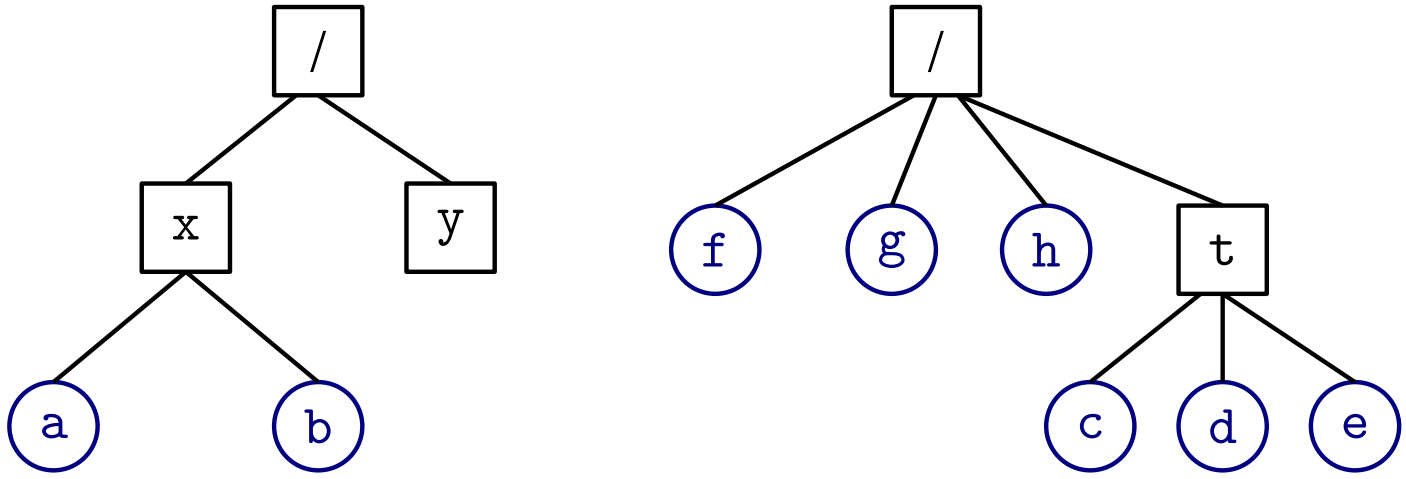

Après :

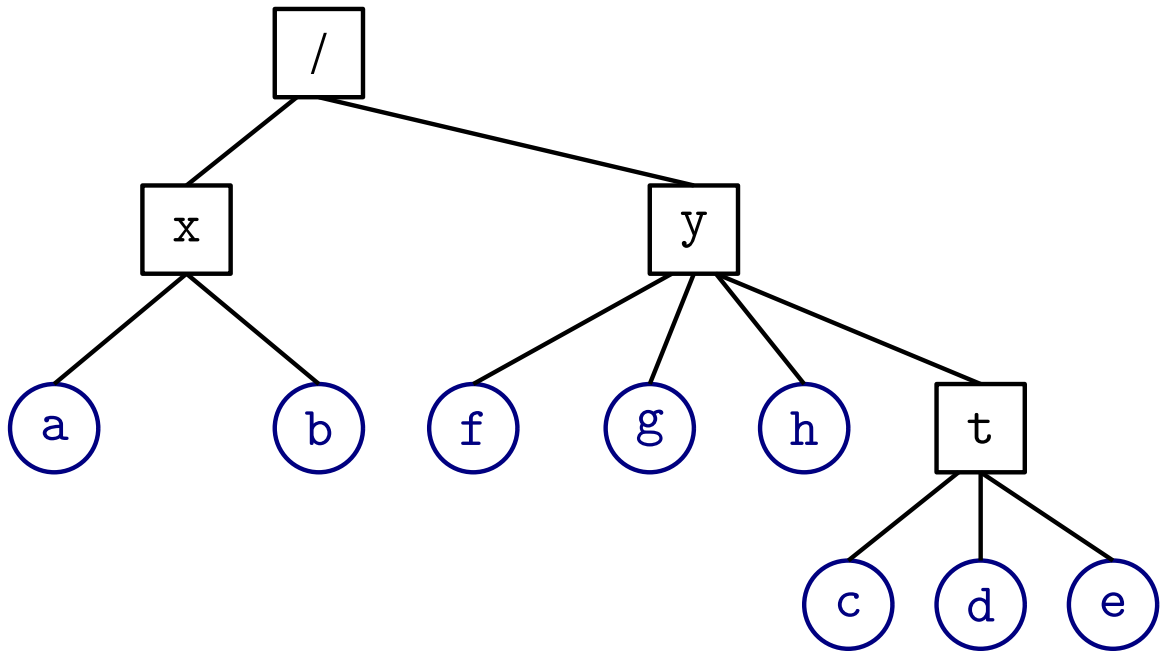

Montage : remarques

Unix

- commandes `mount` et `umount`
  - exemple : `mount -l` pour lister les montages

Démontage

- aussi appelé «retirer le périphérique en toute sécurité»
- demande au noyau de
  - finir toutes les écritures en cours
  - refuser tous les nouveaux accès
  - ensuite, dissocier le sous-arbre de son point de montage
- on peut ensuite débrancher la clé, éjecter le CD...

Remarque : déplacer $\neq$ renommer ?

- sur un même volume ▶ simple modification de répertoires
- entre deux volumes ▶ il faut copier les données !

Plan

1. Introduction : définitions, vocabulaire
2. Interface utilisateur : fichiers, répertoires, volumes
3. Implémentation et interface vers le matériel

Systèmes de fichiers : pourquoi c'est difficile

Non-volatilité : chaque écriture sur le disque est définitive

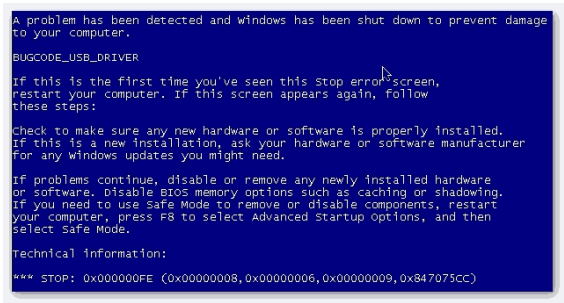

VS

- comment résister aux pannes et aux plantages ?

Latence : un accès disque $\approx$ cent mille accès mémoire !

DRAM $\approx$ 50ns Flash $\approx$ 50μs disque $\approx$ 5ms

Taille : 100$\times$, 1000$\times$ plus vaste que mémoire

- comment offrir une performance acceptable ?

Profils d'accès

Accès séquentiel

- contenu du fichier traité au fur et à mesure
- scénario le plus courant
- exemples : lecture de film, sauvegarde d'un document

Accès arbitraire (VO *Random Access*) :

- contenu du fichier traité dans le désordre
- exemples : bases de données, swap de mémoire virtuelle

Remarques :

- lire un certain secteur $\approx$ *5*ms
- lire un certain secteur et les n suivants $\approx$ *5*ms + $n \times \varepsilon$

Formulation du problème

Objectifs du système de fichiers

- pouvoir retrouver un fichier à partir de son nom
- accéder efficacement aux données (séquentiel et arbitraire)
- gérer l'espace libre : allocation et désallocation des secteurs

Hypothèses

- granularité d'accès par les applications : 1 octet
- granularité de stockage et de transfert : 1 secteur
- méta-données uniquement stockées sur le disque

Observations empiriques

- grande majorité de petits fichiers ($\leqslant$ 10kB)
- mais : espace surtout occupé par les gros fichiers (qq MB)
- et parfois quelques très très gros fichiers ($\geqslant$ 10GB)

Notion de «formattage»

Secteur = unité de lecture ou écriture atomique

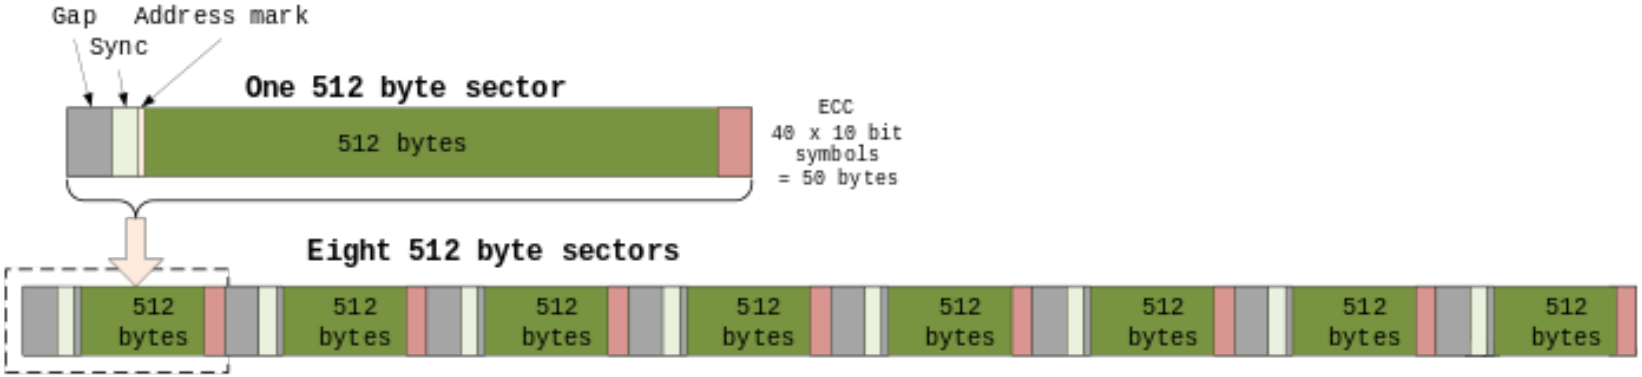

Partitionnement = découpage du disque en volumes

- un volume = un même *File System*
- fichiers (NTFS, FAT, ext4) vs swap vs DBFS vs ...

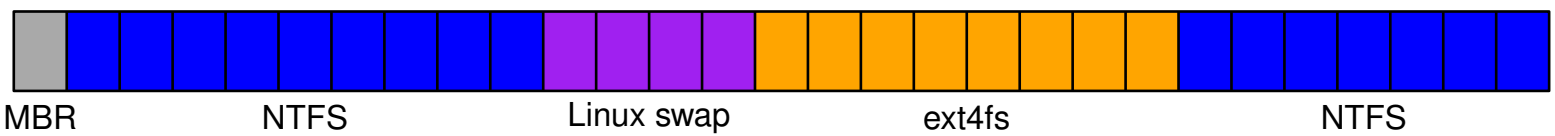

Formattage d'un volume = écriture d'un FS «vide», par ex :

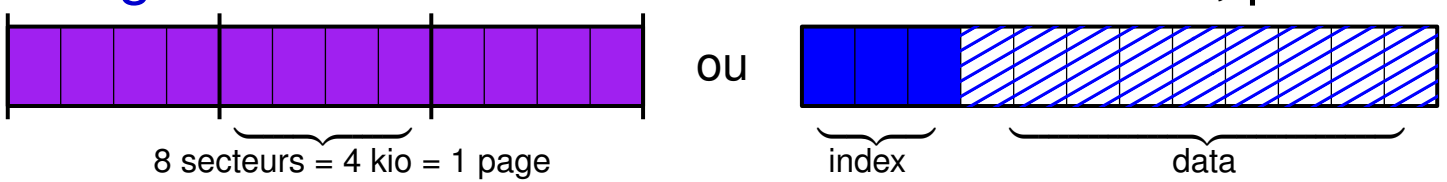

Index = table des matières. typiquement exprimé en termes de numéros de blocs AKA clusters. 1 bloc = 2^n secteurs

Approche 1 : allocation contiguë

Idée : un fichier = une suite de blocs consécutifs

- info nécessaire = n° du 1er bloc, taille du fichier

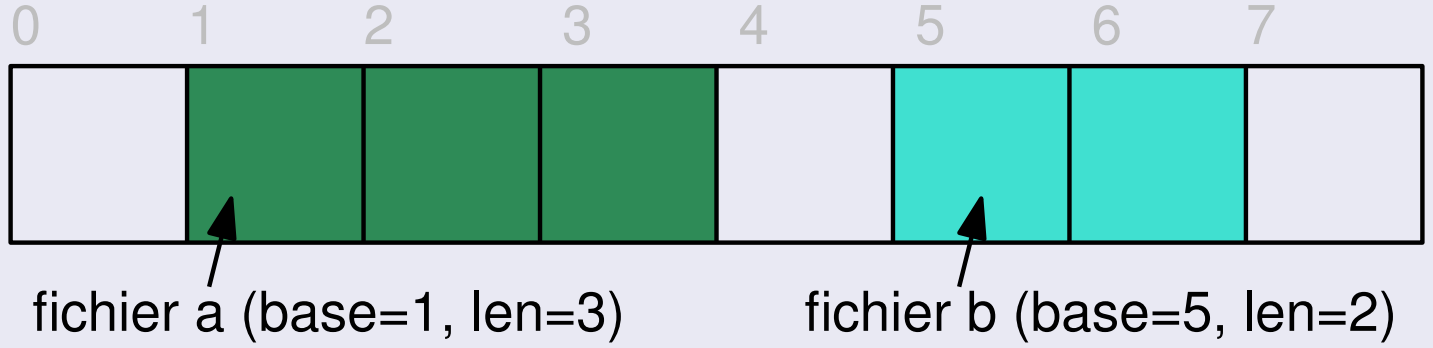

index = pointeur vers le dossier racine

Avantages

- implem simple, accès séquentiel et arbitraire efficaces

Inconvénients

- obligation de connaître la taille du fichier à l'avance
- suppression ▶ fragmentation (externe)

▶ parfait pour supports en lecture seule : CD, DVD

Approche 2 : liste chaînée

Idée : un fichier = une liste chaînée de blocs

- premier mot du bloc = indique le n° du bloc suivant
- info nécessaire = n° du 1er bloc

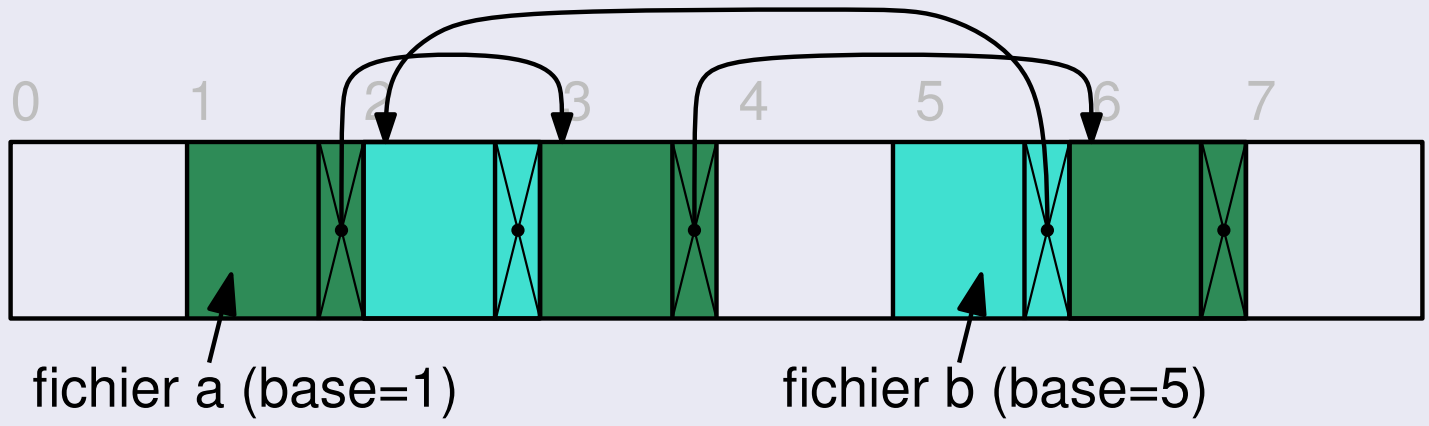

Avantages

- taille dynamique, pas de fragmentation, accès séquentiel

Inconvénients

- accès arbitraire inefficace
- surcoût de stockage des pointeurs
- fragile en cas de bug / crash

Approche 2.5 : File Allocation Table

MS-DOS 1977

Idée : séparer le chaînage et le contenu des fichiers

- FAT = tableau avec 1 case par bloc
- chaque case = n° du bloc suivant (dans le même fichier)

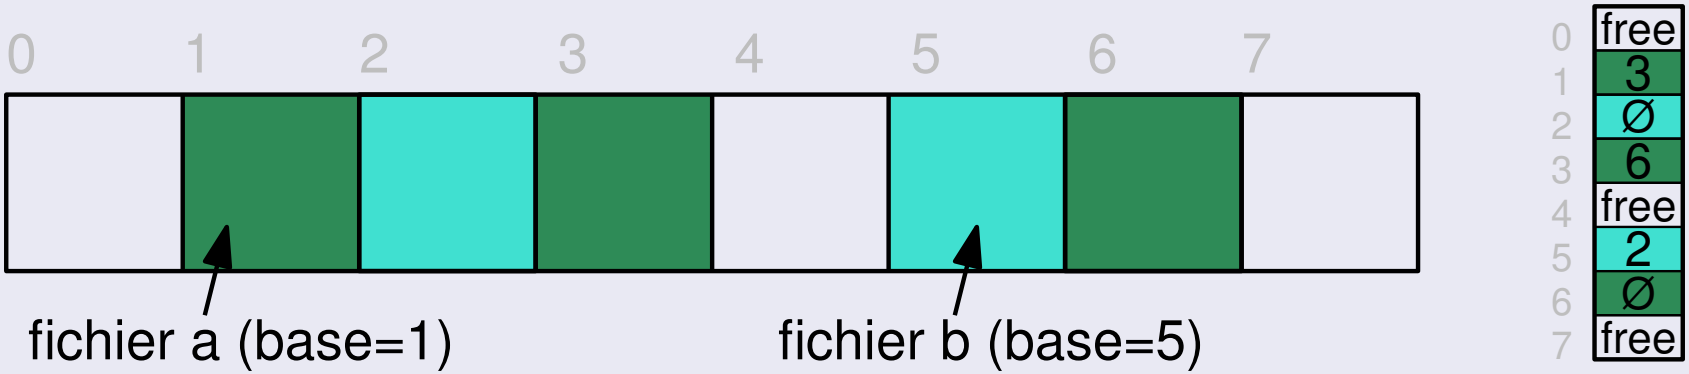

Index = pointeur sur le dossier racine + File Allocation Table

Avantages

- FAT mise en cache en RAM ▶ accès arbitraire OK
- meilleure robustesse
  - redondance : plusieurs exemplaires sur le disque
  - données vs méta-données

Inconvénients

- consommation mémoire

Approche 3 : fichiers indexés

Idée : associer à chaque fichier un tableau de n^{os} de blocs

- inode = «index-node»
- alloué (dans l'index) lors de la création du fichier
- vs secteurs alloués au fur et à mesure de la croissance

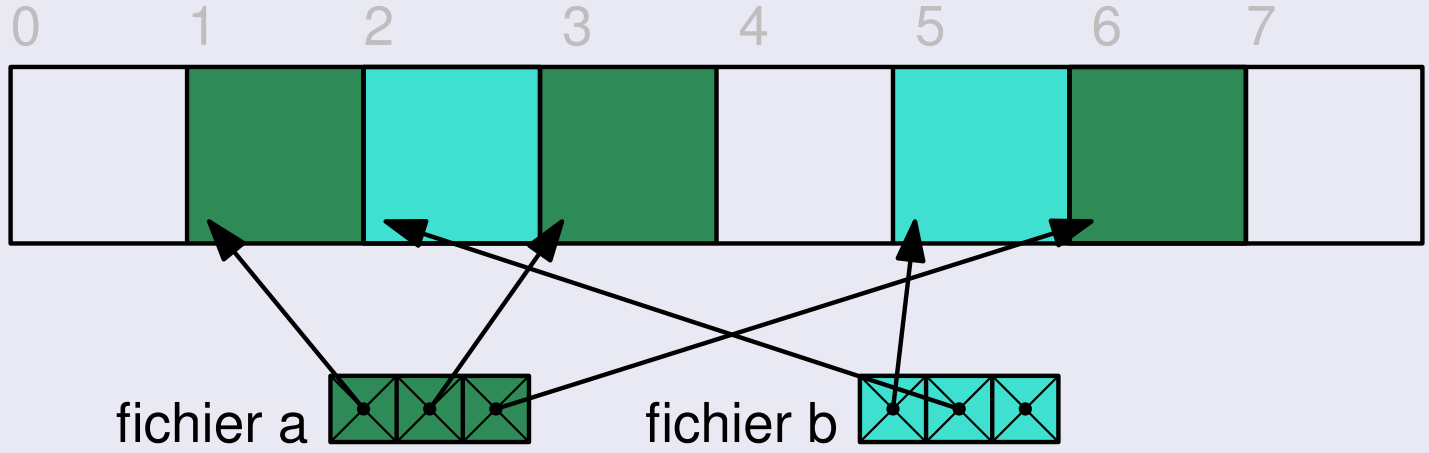

Avantages

- accès séquentiel et arbitraire efficaces

Inconvénients

- chaque inode doit être contigu : problème de fragmentation !

Index = 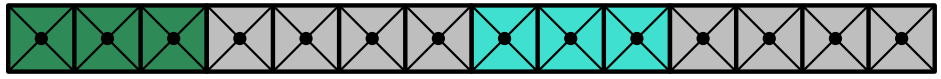

Approche 4 : indexation multi-niveaux

BSD Unix 1984

Idée : organiser l'index lui-même comme un arbre

- une seule taille d'inode : métadonnées + *N* pointeurs
- 12 premiers pointeurs ▶ 12 premiers blocs du fichier
- 13e pointeur ▶ un tableau de pointeurs (*indirect block*)
- 14e pointeur ▶ un tableau de pointeurs vers des *indirect blocks*

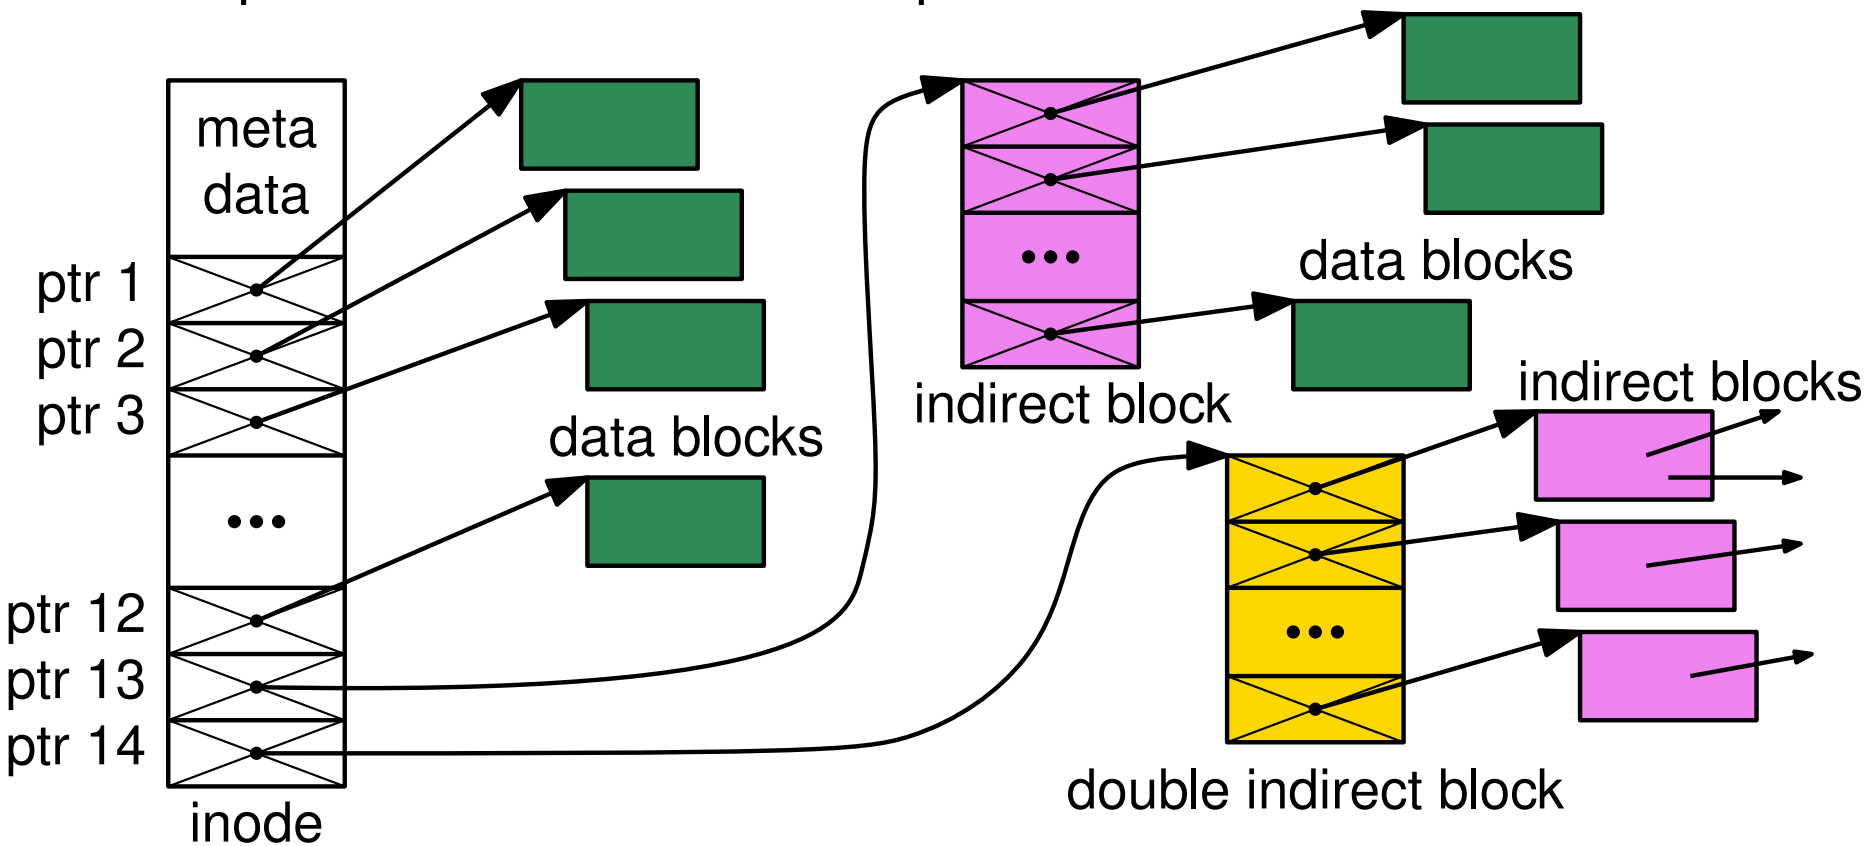

Indexation multi-niveaux Unix : remarques

Avantages

- implem simple, accès efficace aux petits fichiers
- taille max des fichiers bornée, mais grande
  - ext4fs : 15^{e} pointeur vers un *triple indirect block*

Inconvénients

- nombre d'accès au pire cas pour une lecture ?
- pire surcoût en espace ?

▶ systèmes de fichiers modernes = hybrides
- allocation contiguë pour petits fichiers
- indexation multi-niveaux pour gros fichiers

Plan

1. Introduction : définitions, vocabulaire
2. Interface utilisateur : fichiers, répertoires, volumes
3. Implémentation et interface vers le matériel

Systèmes de fichiers : à retenir

Rôles du système de fichiers

- persistence, organisation, gestion du stockage, protection...
- interface : appels système `open()`, `read()`, `write()`...

Notions clés

- fichier = séquence d'octets, identifié par un nom
- dossier = contient des fichiers et d'autres dossiers
- volume = arborescence occupant tout un support

Implémentation

- dossier = fichier spécial contenant des noms
- fichier = éparpillé sur plusieurs secteurs du disque
- inode = index des secteurs composant le fichier