

# IN 406 – Théorie des Langages

## Cours 1 : Mot, langage et automate

Franck Quessette – [Franck.Quessette@uvsq.fr](mailto:Franck.Quessette@uvsq.fr)

Université de Versailles – Saint-Quentin

V3 2019–2020

# Organisation de l'UE

- ▶ 12 Cours et 12 TD ;
- ▶ [Franck Quessette](#) pour les huit premiers cours ;
- ▶ [Guillaume Scerri](#) pour les 4 derniers ;
- ▶ 5 groupes de TD :
  - Gr 3 : lundi 13h40-15h10 Amphi I [Xavier Badin de Montjoye](#) ;
  - Gr 1, 2 et DL : mardi 09h40-12h50 Salles G002, RC22, D101  
[Loric Duhazé](#), [Franck Quessette](#), [Yann Strozecki](#) ;
  - Gr 4 : mardi 13h50-15h10 Salle G210 [Guillaume Scerri](#).
- ▶ 1 note de CC (1/3) et une note d'examen (2/3) ;
- ▶ CC : projet + contrôle.

# Objectifs de l'UE

Définir et montrer l'utilisation d'outils mathématiques :

- ▶ alphabet, mot, langage ;
- ▶ expression régulière ;
- ▶ grammaire ;
- ▶ automate, automate à pile ;
- ▶ machine de Turing.

Introduction aux modèles de calculs :

- ▶ machine de Turing ;
- ▶ calculabilité.

# Alphabet, mot

## Définition

Un **alphabet** est un ensemble **fini** de symboles, appelés lettres ou caractères. Cet ensemble est généralement noté  $\Sigma$  (sigma).

## Exemples

- ▶  $\Sigma_1 = \{a, b\}$ , un alphabet à deux lettres ;
- ▶  $\Sigma_2 = \{a_1, a_2, \dots, a_n\}$ , un alphabet à  $n$  lettres.

## Définition

Un **mot** sur un alphabet  $\Sigma$  est une concaténation **finie** de lettres de  $\Sigma$ .

## Exemples

Soit  $\Sigma = \{a, b, c\}$  un alphabet,

- ▶  $w_1 = abc$ , est un mot de trois lettres.  $w_2 = aabaa$ , est un mot de cinq lettres, chaque lettre peut apparaître plusieurs fois ;
- ▶  $w_1 = abc$  et  $w_3 = acb$  sont deux mots différents, la concaténation n'est pas commutative.
- ▶ La concaténation est parfois notée :  $w = a \cdot b \cdot c$ .
- ▶  $w_4 = c$  est un mot.

Attention  $a$  représente à la fois la lettre  $a$  et le mot d'une seule lettre  $a$  qui est parfois notée " $a$ ".

## Concaténation

La concaténation peut être définie entre deux lettres, entre deux mots ou entre un mot et une lettre :

Soient  $\Sigma = \{a, b, c\}$  un alphabet, et  $w_1 = abc$  et  $w_2 = aabaa$  des mots sur l'alphabet  $\Sigma$  alors,

$w_1c = abcc$ ,  $bw_1 = babc$  et  $w_1w_2 = abcaabaa$  sont des mots sur l'alphabet  $\Sigma$ .

### Définition

La **taille** ou **longueur** d'un mot  $w$  est le nombre de lettres qui le composent, ce nombre est noté  $|w|$ . De plus, la notation  $|w|_a$  est le nombre d'occurrences de la lettre  $a$  dans le mot  $w$ .

### Exemple

Si  $w = aabaa$  est un mot sur l'alphabet  $\Sigma = \{a, b, c\}$ , alors  $|w| = 5$ ,  $|w|_a = 4$ ,  $|w|_b = 1$  et  $|w|_c = 0$ .

## Préfixe, suffixe

### Définition

Un mot  $w_1$  est un **préfixe** d'un mot  $w$  s'il existe un mot  $w_2$  tel que  $w = w_1 w_2$ .

Un mot  $w_2$  est un **suffixe** d'un mot  $w$  s'il existe un mot  $w_1$  tel que  $w = w_1 w_2$ .

### Définition

Le caractère  $\varepsilon$  (epsilon) est le caractère vide, il est tel que pour tout mot  $w$ ,  $w\varepsilon = \varepsilon w = w$ .

$\varepsilon$  représente également le mot vide :  $|\varepsilon| = 0$ .

### Exemple

Si  $w = aabc$ , les préfixes de  $w$  sont :  $\varepsilon$ ,  $a$ ,  $aa$ ,  $aab$  et  $aabc$  et les suffixes de  $w$  sont :  $aabc$ ,  $abc$ ,  $bc$ ,  $c$  et  $\varepsilon$ .

# Notations

## Notations

- ▶ Pour simplifier l'écriture, un mot composé de caractères identiques  $aaa$  peut être noté  $a^3$ .
- ▶ De même pour des sous-mots,  $w = aabbaaa = a^2b^2a^3$ .
- ▶ Généralisation aux mots, si  $w = abc$ , alors  $w^2 = abcabc$ ,  $w^1 = w$  et  $w^0 = \varepsilon$ .



# Langage

## Définition

Un **langage** sur un alphabet  $\Sigma$  est un ensemble **fini** ou **infini** de mots.

## Exemples

Soit l'alphabet  $\Sigma = \{a, b, c\}$

- ▶  $L_0 = \emptyset$ , ce langage ne contient aucun mot ;
- ▶  $L_1 = \{\varepsilon\}$ , ce langage contient un mot qui est le mot vide, donc  $L_1 \neq L_0$  ;
- ▶  $L_2 = \{abc, bca, bbb\}$ , ensemble fini ;
- ▶  $L_3 = \{a^n, n \geq 0\}$ , ensemble infini ;
- ▶  $L_4$  l'ensemble des mots qui contiennent un nombre pair de  $c$ .

Un langage peut-être défini en français, par une formule ou bien à l'aide d'un formalisme mathématique : expression régulière, grammaire, automate, ...

# Différents types de problèmes

Problème de **calcul** :

## Exemples

- ▶ multiplier deux nombres ;
- ▶ factoriser deux nombres.

Problème d'**optimisation** :

## Exemples

- ▶ calculer le plus court chemin d'ici à là ;
- ▶ découper des pièces dans un morceau de tissu pour minimiser les chutes ;
- ▶ affecter les personnels navigants sur les avions en minimisant les coûts.

# Problème de décision

Problème de **décision** : question avec une réponse OUI/NON.

## Exemples

- ▶ ce graphe est-il planaire ?
- ▶ ce nombre est-il premier ?
- ▶ cette machine de Turing s'arrête-t-elle toujours ?
- ▶ ce mot appartient-il à ce langage ?

Tous les problèmes peuvent se ramener à des problèmes de décision ou au moins à une suite de problèmes de décisions.

QUESTION FONDAMENTALE :

Soit  $L$  un langage et  $w$  un mot, est-ce que  $w \in L$  ?

# Réponse automatique à la question fondamentale

## QUESTION FONDAMENTALE :

Soit  $L$  un langage et  $w$  un mot, est-ce que  $w \in L$  ?

Peut-on construire une machine universelle qui répond à la question fondamentale pour tout langage et tout mot ?

La réponse est NON,  
il n'existe pas de machine universelle.

Ce que l'on va faire dans ce cours :

Classification des langages et des machines permettant  
de répondre à la question fondamentale.

# Concaténation de langages

## Définition

La concaténation de deux langages  $L_1$  et  $L_2$  est notée  $L = L_1 L_2$  est définie par :

$$w \in L \iff \exists w_1 \in L_1, \exists w_2 \in L_2, \text{ tels que } w = w_1 w_2$$

## Exemples

- ▶  $L = \{ab, b\}$ ,  $LL = \{abab, abb, bab, bb\}$
- ▶  $L_1 = \{ab, b\}$ ,  $L_2 = \{bb, ba\}$ ,  $L_1 L_2 = \{abbb, abba, bbb, bba\}$ .
- ▶  $L_1 = \{ab, a\}$ ,  $L_2 = \{ba, a\}$ ,  $L_1 L_2 = \{abba, aba, aa\}$ .

# Puissance d'un langage

## Définition

La **puissance** d'un langage  $L$  est définie par :

- ▶  $L^0 = \{\epsilon\}$  ;
- ▶  $L^n = LL^{n-1}$  pour  $n > 0$ .

Par induction,  $L^1 = L$ .

## Exemples

- ▶  $L = \{ab, b\}$ ,  $LL = L^2 = \{abab, abb, bab, bb\}$

# Étoile de Kleene

## Définition

L' **étoile de Kleene** d'un langage  $L$ , notée  $L^*$  est définie par :

$$L^* = \bigcup_{n=0}^{+\infty} L^n$$

## Exemples

Soit l'alphabet  $\Sigma = \{a, b\}$

- $L = \{a\}$ ,  $L^* = \{a^n, n \geq 0\}$  ;

Un alphabet  $\Sigma$  peut être vu comme un langage ne contenant que des mots d'une lettre et avec  $\Sigma = \{a, b\}$  :

$\Sigma^* = \{\varepsilon, a, b, aa, ab, ba, bb, \dots\}$ , l'ensemble de tous les mots possibles sur l'alphabet  $\Sigma$ .

# Opérations sur les langages

Les langages étant des ensembles, les opérations ensemblistes (union, intersection, complémentaire) sont naturellement définies.

## Exemples

Soit l'alphabet  $\Sigma = \{a, b, c\}$ ,  $L_1$  l'ensemble des mots qui commencent par  $a$  ou  $b$  et  $L_2$  l'ensemble des mots qui commencent par  $b$  ou  $c$ .

- ▶ **Intersection** :  $L_1 \cap L_2$  est l'ensemble des mots qui commencent par  $b$ .
- ▶ **Union** :  $L_1 \cup L_2$  est l'ensemble de **tous** les mots sauf  $\varepsilon$ .
- ▶ **Complémentaire** :  $\overline{L_1} = \Sigma^* \setminus L_1$  est l'ensemble des mots qui commencent  $c \cup \{\varepsilon\}$ .



# Langage rationnel

## Définition

Un **langage rationnel** sur un alphabet  $\Sigma$  est défini par :

- ▶  $L = \emptyset$  est rationnel ;
- ▶  $L = \{\varepsilon\}$  est rationnel ;
- ▶ pour tout  $a \in \Sigma$ ,  $L = \{a\}$  est rationnel ;
- ▶ si  $L_1$  et  $L_2$  sont rationnels alors  $L_1 L_2$  et  $L_1 \cup L_2$  sont rationnels ;
- ▶ si  $L$  est rationnel alors  $L^*$  est rationnel.

## Lemme

Tout langage fini est rationnel.

## Première machine : automate fini

### Définition

Un **automate fini**  $\mathcal{A}$  est un quintuplet  $\mathcal{A} = (\Sigma, Q, q_0, F, T)$  avec :

- ▶  $\Sigma$  un alphabet **fini** ;
- ▶  $Q$  un ensemble **fini** d'états ;
- ▶  $q_0 \in Q$  l'état initial ;
- ▶  $F \subseteq Q$  l'ensemble des états finaux ;
- ▶  $T \subseteq Q \times \Sigma \times Q$  l'ensemble des transitions.

## Première machine : automate fini


### Exemple

$\mathcal{A} = (\Sigma, Q, q_0, F, T)$  avec  $\Sigma = \{a, b\}$ ,  $Q = \{q_0, q_1, q_2, q_3\}$ ,

$F = \{q_2, q_3\}$ ,

$T = \{(q_0, a, q_0), (q_0, a, q_1), (q_0, b, q_2), (q_1, b, q_1), (q_1, b, q_2), (q_1, a, q_3), (q_1, b, q_3), (q_2, a, q_3), (q_3, b, q_2)\}$ .

Représentation graphique :




# Reconnaissance d'un mot

## Définition

Un automate fini  $\mathcal{A} = (\Sigma, Q, q_0, F, T)$  **reconnait** le mot  $w = a_1 a_2 \dots a_k$ , s'il existe une séquence d'états  $q_0^{(w)}, q_1^{(w)}, \dots, q_k^{(w)}$  telle que :

- ▶  $q_0^{(w)} = q_0$  ;
- ▶  $\forall i \in 0..k-1, (q_i^{(w)}, a_{i+1}, q_{i+1}^{(w)}) \in T$  ;
- ▶  $q_k^{(w)} \in F$ .



- ▶  $aaaab$  reconnu avec la séquence d'états  $q_0, q_1, q_1, q_1, q_1, q_2$ .
- ▶  $aba$  non reconnu, pas de transition pour le deuxième  $a$ .
- ▶  $aa$  non reconnu, arrêt dans un état non final.

# Reconnaissance d'un langage

## Définition

Le **langage reconnaissable** par un automate fini  $\mathcal{A}$  est noté  $L(\mathcal{A})$  et est défini par :

$$w \in L(\mathcal{A}) \iff w \text{ est reconnu par } \mathcal{A}$$

Attention à l'équivalence dans la définition.

# Théorème de Kleene

## Théorème de Kleene

Pour tout langage  $L$ ,

$L$  est reconnaissable  $\iff L$  est rationnel.

La preuve est faite en TD.

Voir également : [fr.wikipedia.org/wiki/Théorème\\_de\\_Kleene](https://fr.wikipedia.org/wiki/Théorème_de_Kleene).