

IN 406 – Théorie des Langages

Cours 1 : Mot, langage et automate

Franck Quessette – Franck.Quessette@uvsq.fr

Université de Versailles – Saint-Quentin

V4 2020–2021

Organisation de l'UE

- ▶ 12 Cours et 12 TD ;
- ▶ [Franck Quessette](#) pour les 7 ou 8 premiers cours ;
- ▶ [Yann Strozecki](#) pour les 4 derniers ;
- ▶ Groupes de TD :
 - Gr 1 A et B : vendredi 09h30-12h20 [Franck Quessette](#)
 - Gr 2 A et B : vendredi 09h30-12h20 [Sandrine Vial](#)
 - Gr 3 A et B : mercredi 09h30-12h20 [Pierre Coucheney](#)
 - Gr 4 A et B : mercredi 09h30-12h20 [Yann Strozecki](#)
 - Gr DLBI A et B : vendredi 14h30-17h20 [Xavier Badin de Montjoye](#)
- ▶ 1 note de CC (1/3) et une note d'examen (2/3) ;
- ▶ CC : projet + contrôle.

Objectifs de l'UE

Définir et montrer l'utilisation d'outils mathématiques :

- ▶ alphabet, mot, langage (FQ) ;
- ▶ expression régulière (FQ) ;
- ▶ grammaire (FQ/YS) ;
- ▶ automate, automate à pile (FQ) ;
- ▶ machine de Turing (YS).

Introduction aux modèles de calculs :

- ▶ machine de Turing (YS) ;
- ▶ calculabilité (YS).

Alphabet, mot

Définition

Un **alphabet** est un ensemble **fini** de symboles, appelés lettres ou **caractères**. Cet ensemble est généralement noté Σ (sigma).

Exemples

- ▶ $\Sigma_1 = \{a, b\}$, un alphabet à deux lettres ;
- ▶ $\Sigma_2 = \{a_1, a_2, \dots, a_n\}$, un alphabet à n lettres.

Définition

Un **mot** sur un alphabet Σ est une concaténation **finie** de lettres de Σ .

Exemples

Soit $\Sigma = \{a, b, c\}$ un alphabet,

- ▶ $w_1 = abc$, est un mot de trois lettres. $w_2 = aabaa$, est un mot de cinq lettres, chaque lettre peut apparaître plusieurs fois ;
- ▶ $w_1 = abc$ et $w_3 = acb$ sont deux mots différents, la concaténation n'est pas commutative.
- ▶ La concaténation est parfois notée : $w = a \cdot b \cdot c$.
- ▶ $w_4 = c$ est un mot.

Attention a représente à la fois la lettre a et le mot d'une seule lettre a qui est parfois notée " a ".

Concaténation

La concaténation peut être définie entre deux lettres, entre deux mots ou entre un mot et une lettre :

Soient $\Sigma = \{a, b, c\}$ un alphabet, et $w_1 = abc$ et $w_2 = aabaa$ deux mots sur l'alphabet Σ alors,

$w_1c = abcc$, $bw_1 = babc$ et $w_1w_2 = abcaabaa$ sont des mots sur l'alphabet Σ .

Définition

La **taille** ou **longueur** d'un mot w est le nombre de lettres qui le composent, ce nombre est noté $|w|$. De plus, la notation $|w|_a$ est le nombre d'occurrences de la lettre a dans le mot w .

Exemple

Si $w = aabaa$ est un mot sur l'alphabet $\Sigma = \{a, b, c\}$, alors $|w| = 5$, $|w|_a = 4$, $|w|_b = 1$ et $|w|_c = 0$.

Préfixe, suffixe, mot vide

Définition

Un mot w_1 est un **préfixe** d'un mot w s'il existe un mot w_2 tel que $w = w_1 w_2$.

Un mot w_2 est un **suffixe** d'un mot w s'il existe un mot w_1 tel que $w = w_1 w_2$.

Définition

Le caractère ε (epsilon) est le caractère vide, il est tel que pour tout mot w , $w\varepsilon = \varepsilon w = w$.

Attention, ε ne fait jamais partie de l'alphabet.

ε représente également le mot vide, c'est à dire un mot avec zéro lettres : $|\varepsilon| = 0$.

Exemple

Si $w = aabc$, les préfixes de w sont : ε , a , aa , aab et $aabc$ et les suffixes de w sont : $aabc$, abc , bc , c et ε .

Notations

Notations

- ▶ Pour simplifier l'écriture, un mot composé de caractères identiques aaa peut être noté a^3 .
- ▶ De même pour des sous-mots, $w = aabbbaaa = a^2b^2a^3$.
- ▶ Généralisation aux mots, si $w = abc$, alors $w^2 = abcabc$, $w^1 = w$ et $w^0 = \varepsilon$.

Langage

Définition

Un **langage** sur un alphabet Σ est un ensemble **fini** ou **infini** de mots.

Exemples

Soit l'alphabet $\Sigma = \{a, b, c\}$

- ▶ $L_0 = \emptyset$, ce langage ne contient aucun mot ;
- ▶ $L_1 = \{\varepsilon\}$, ce langage contient un mot qui est le mot vide, donc $L_1 \neq L_0$;
- ▶ $L_2 = \{abc, bca, bbb\}$, ensemble fini ;
- ▶ $L_3 = \{a^n, n \geq 0\}$, ensemble infini ;
- ▶ L_4 l'ensemble des mots qui contiennent un nombre pair de c .

Un langage peut-être défini en français, par une formule ou bien à l'aide d'un formalisme mathématique : expression régulière, grammaire, automate, ...

Différents types de problèmes

Problème de **calcul** :

Exemples

- ▶ multiplier deux nombres ;
- ▶ factoriser deux nombres.

Problème d'**optimisation** :

Exemples

- ▶ calculer le plus court chemin d'ici à là ;
- ▶ découper des pièces dans un morceau de tissu pour minimiser les chutes ;
- ▶ affecter les personnels navigants sur les avions en minimisant les coûts.

Problème de décision

Problème de **décision** : question avec une réponse OUI/NON.

Exemples

- ▶ ce graphe est-il planaire ?
- ▶ ce nombre est-il premier ?
- ▶ cette machine de Turing s'arrête-t-elle toujours ?
- ▶ ce mot appartient-il à ce langage ?

Tous les problèmes peuvent se ramener à des problèmes de décision ou au moins à une suite de problèmes de décisions.

QUESTION FONDAMENTALE :

Soit L un langage et w un mot, est-ce que $w \in L$?

Réponse automatique à la question fondamentale

QUESTION FONDAMENTALE :

Soit L un langage et w un mot, est-ce que $w \in L$?

Peut-on construire une machine universelle qui répond à la question fondamentale pour tout langage et tout mot ?

La réponse est NON,
il n'existe pas de machine universelle.

Ce que l'on va faire dans ce cours :

Classification des langages et des machines permettant
de répondre à la question fondamentale.

Concaténation de langages

Définition

La concaténation de deux langages L_1 et L_2 est notée $L = L_1 L_2$ est définie par :

$$w \in L \iff \exists w_1 \in L_1, \exists w_2 \in L_2, \text{ tels que } w = w_1 w_2$$

Exemples

- ▶ $L = \{ab, b\}$, $LL = \{abab, abb, bab, bb\}$
- ▶ $L_1 = \{ab, b\}$, $L_2 = \{bb, ba\}$, $L_1 L_2 = \{abbb, abba, bbb, bba\}$.
- ▶ $L_1 = \{ab, a\}$, $L_2 = \{ba, a\}$, $L_1 L_2 = \{abba, aba, aa\}$.

Puissance d'un langage

Définition

La **puissance** d'un langage L est définie par :

- ▶ $L^0 = \{\epsilon\}$;
- ▶ $L^n = LL^{n-1}$ pour $n > 0$.

Par induction, $L^1 = L$.

Exemples

- ▶ $L = \{ab, b\}$, $LL = L^2 = \{abab, abb, bab, bb\}$

Étoile de Kleene

Définition

L' **étoile de Kleene** d'un langage L , notée L^* est définie par :

$$L^* = \bigcup_{n=0}^{+\infty} L^n$$

Exemples

Soit l'alphabet $\Sigma = \{a, b\}$

- $L = \{a\}$, $L^* = \{a^n, n \geq 0\}$;

Un alphabet Σ peut être vu comme un langage ne contenant que des mots d'une lettre et avec $\Sigma = \{a, b\}$:

$\Sigma^* = \{\varepsilon, a, b, aa, ab, ba, bb, \dots\}$, l'ensemble de tous les mots possibles sur l'alphabet Σ .

Opérations sur les langages

Les langages étant des ensembles, les opérations ensemblistes (union, intersection, complémentaire) sont naturellement définies.

Exemples

Soit l'alphabet $\Sigma = \{a, b, c\}$, L_1 l'ensemble des mots qui commencent par a ou b et L_2 l'ensemble des mots qui commencent par b ou c .

- ▶ **Intersection** : $L_1 \cap L_2$ est l'ensemble des mots qui commencent par b .
- ▶ **Union** : $L_1 \cup L_2$ est l'ensemble de **tous** les mots sauf ε .
- ▶ **Complémentaire** : $\overline{L_1} = \Sigma^* \setminus L_1$ est l'ensemble des mots qui commencent $c \cup \{\varepsilon\}$.

Langage rationnel

Définition

Un **langage rationnel** sur un alphabet Σ est défini par :

- ▶ $L = \emptyset$ est rationnel ;
- ▶ $L = \{\varepsilon\}$ est rationnel ;
- ▶ pour tout $a \in \Sigma$, $L = \{a\}$ est rationnel ;
- ▶ si L_1 et L_2 sont rationnels alors $L_1 L_2$ et $L_1 \cup L_2$ sont rationnels ;
- ▶ si L est rationnel alors L^* est rationnel.

Lemme

Tout langage fini est rationnel.

Première machine : automate fini

Définition

Un **automate fini** \mathcal{A} est un quintuplet $\mathcal{A} = (\Sigma, Q, q_0, F, T)$ avec :


- ▶ Σ un alphabet **fini** ;
- ▶ Q un ensemble **fini** d'états ;
- ▶ $q_0 \in Q$ l'état initial ;
- ▶ $F \subseteq Q$ l'ensemble des états finaux ;
- ▶ $T \subseteq Q \times \Sigma \times Q$ l'ensemble des transitions.

Première machine : automate fini

Exemple

$\mathcal{A} = (\Sigma, Q, q_0, F, T)$ avec $\Sigma = \{a, b\}$, $Q = \{q_0, q_1, q_2, q_3\}$,
 $F = \{q_2, q_3\}$,
 $T = \{(q_0, a, q_0), (q_0, a, q_1), (q_0, b, q_2), (q_1, b, q_1), (q_1, b, q_2),$
 $(q_1, a, q_3), (q_1, b, q_3), (q_2, a, q_3), (q_3, b, q_2)\}$.

Représentation graphique :




Reconnaissance d'un mot

Définition

Un automate fini $\mathcal{A} = (\Sigma, Q, q_0, F, T)$ **reconnait** le mot $w = a_1 a_2 \dots a_k$, s'il existe une séquence d'états $q_0^{(w)}, q_1^{(w)}, \dots, q_k^{(w)}$ telle que :

- ▶ $q_0^{(w)} = q_0$;
- ▶ $\forall i \in 0..k-1, (q_i^{(w)}, a_{i+1}, q_{i+1}^{(w)}) \in T$;
- ▶ $q_k^{(w)} \in F$.



- ▶ *aaaab* reconnu avec la séquence d'états $q_0, q_1, q_1, q_1, q_1, q_2$.
- ▶ *aba* non reconnu, pas de transition pour le deuxième *a*.
- ▶ *aa* non reconnu, fin dans un état non final.

Reconnaissance d'un langage

Définition

Le **langage reconnaissable** par un automate fini \mathcal{A} est noté $L(\mathcal{A})$ et est défini par :

$$w \in L(\mathcal{A}) \iff w \text{ est reconnu par } \mathcal{A}$$

Attention à l'équivalence dans la définition.

Théorème de Kleene

Théorème de Kleene

Pour tout langage L ,

L est reconnaissable $\iff L$ est rationnel.

La preuve est faite en TD.

Voir également : fr.wikipedia.org/wiki/Théorème_de_Kleene.